这门课是一门很难评价的课，理解门槛有点高。

Darkmaster
2025.03.11.

1. Nonlinear Programming.

这一章是OC的一些基础理论，类似于引入。

$$\min_x f(x) \quad \text{s.t. } g(x) \le 0,\ h(x) = 0.$$

解决的是这类问题。

① Convex set and function.

convex set: $x, y \in C$, $z = \lambda x + (1-\lambda)y$, $\lambda \in [0,1]$, $z \in C$. $\Rightarrow C$ convex.

convex function: $f(\lambda x + (1-\lambda)y) \le \lambda f(x) + (1-\lambda) f(y)$

如何证明 convex function

first order: $f(y) \ge f(x) + \nabla f(x)^T (y-x) \quad \forall x, y \in C$

★ second order: $\nabla_{xx} f(x) \ge 0 \quad \forall x \in C$.

$\nabla_{xx} f(x) > 0 \longrightarrow$ strict convex.

注：在有多个变量时，$\nabla_{xx} f(x)$ 是一个矩阵。 $(\nabla_{xx} f)_{i,j} = \frac{\partial^2 f}{\partial x_i \partial x_j}$

常用 second order，first order 很少使用。

② local and global min.

x^* local min. $\xrightarrow{\text{necessary}}$ $\nabla f(x^*) = 0 \quad \nabla_{xx} f(x^*) \ge 0$

$\nabla f(x^*) = 0$, $f(x)$ convex on $\mathbb{R}^n \xrightarrow{\text{sufficient}}$ x^* global min.

★ $\nabla f(x^*) = 0$, $\nabla_{xx} f(x^*) > 0 \xrightarrow{\text{sufficient}}$ x^* strict local min.

这个东西在几乎每一章都用得上。

③ Constrained problems and KKT conditions.

有两种 constraints.

- $g(x) \le 0$.

  active set $A(\bar{x}) = \{i \mid g_i(\bar{x}) = 0\}$.

KKT. $\nabla f(\bar{x}) + \nabla g(\bar{x}) = 0$

$\bar{v} \ge 0$

$g(\bar{x}) \le 0$

$\bar{v}^T g(\bar{x}) = 0$

x^* local min $\xrightarrow{\text{necessary}}$ unique KKT point (x^*, v^*)

f differentiable and convex, (x^*, v^*) KKT point $\xrightarrow{\text{suff.}}$ x^* gbbal min.

g convex

- $h(x) = 0$

  tangent set. $T_{\bar{x}}^0 = \{d \in \mathbb{R}^n \mid \nabla h(\bar{x})^T d = 0\}$ d 与 $h(x)$ 正交.

first order: x^* local min. $\xrightarrow{\text{nec.}}$ unique λ^* $h(x^*) = 0$

$\nabla f(x^*) + \nabla h(x^*) \lambda^* = 0$

second order: x^* local min. $\xrightarrow{\text{nec.}}$ unique λ^* $h(x^*) = 0$

$\nabla f(x^*) + \nabla h(x^*) \lambda^* = 0$

$d^T (\nabla_{xx} f(x^*) + \nabla_{xx} h(x^*)^T \lambda^*) d \ge 0 \quad \forall d \in T_{\bar{x}}^0$

$h(x^*) = 0$

$\nabla f(x^*) + \nabla h(x^*) \lambda^* = 0$

$d^T (\nabla_{xx} f(x^*) + \nabla_{xx} h(x^*)^T \lambda^*) d > 0 \quad \forall d \in T_{\bar{x}}^0, d \ne 0$

$\xrightarrow{\text{suff.}}$ x^* strict local min.

考虑泛用情况. 同时出现 $g(x)$, $h(x)$.

$$L(x,v,\lambda) = f(x) + v^T g(x) + \lambda^T h(x)$$

KKT: $\nabla L(x,v,\lambda) = 0$

$g(\bar{x}) \leq 0$

$h(\bar{x}) = 0$

$\bar{v} \geq 0$

$\bar{v}^T g(x) = 0$ 从这里入手来解.

分别让 $g(x)=0$ 去解. (active)

x^* local min. $\overset{\text{nec.}}{\Longrightarrow}$ KKT point (x^*, v^*, λ^*) unique.

$y^T \nabla_{xx} L(x^*,v^*,\lambda^*) y \geq 0$

for all $\nabla g_i(x^*) y^T = 0$

$\nabla h(x^*) y^T = 0$

$i \in A(x)$ → 只有 active 的 g 需要.

KKT point (x^*, v^*, λ^*)

* 满足 $y^T \nabla_{xx} L(x^*,v^*,\lambda^*) y > 0$ 的 y. 也满足 (for all $y \neq 0$)

$\nabla h(x^*)^T y = 0$

$\nabla g_i(x^*)^T y = 0$ for $v_i > 0$

$\nabla g_i(x^*)^T y \leq 0$ for $v_i = 0$

$i \in A(x)$

$\overset{\text{suff.}}{\Longrightarrow}$ x^* strict local min.

(x^*, v^*, λ^*) KKT point, f, g convex, h affine $\overset{\text{suff.}}{\Longrightarrow}$ x^* global min.

这个方法在尝试证 local min. 时很好用. 因为在 $g(x)$ 中只提供了 global min 的证法.

但用这个方法时. 一定不要忘记判断 $g_i(x)$ 是不是 active.

其实实际应用时. 难点在于解 KKT point 时的分类讨论.

2. Calculus of Variations (CV 变分).

从这里开始就有点玄幻了.

continuously , piecewise continuously.

$C^1([s_1,s_2],\mathbb{R}^n)$ $s_1\sim s_2$ 间的连续函数.

$\hat{C}^1([s_1,s_2],\mathbb{R}^n)$ $s_1\sim s_2$ 间的分段连续函数. 有间断点, $x(c_i^-)=x(c_i^+)$, $\dot{x}(c_i^-)\neq\dot{x}(c_i^+)$

strong norm.

$$\|x\|_\infty=\max_{s_1\le s\le s_2}\|x(s)\|$$

Global $\Rightarrow$ Strong $\Rightarrow$ weak

$\Rightarrow$ strong local min. Def. H.2.2

weak local min.

weak norm.

$$\|x\|_1=\|x\|_\infty+\max_{s_1\le s\le s_2}\|\dot{x}(s)\|$$

本章解决的问题.

$$\min_{x\in V,(s_2)} J(x)$$

$$\text{s.t. } x\in D$$

$$J(x)=\int_{s_1}^{s_2} l(s,x(s),\dot{x}(s))\,ds.$$ Lagrangian form

$$J(x)=\varphi(s_2,x(s_2))+\int_{s_1}^{s_2} l(s,x(s),\dot{x}(s))\,ds$$ Bolza form

$$J(x)=\varphi(s_2,x(s_2))$$ Mayer form

先研究 $C^1([s_1,s_2])$. fixed end point. fixed s_2

① Euler equations. (EE)

$$\frac{d}{ds}l_{\dot{x}}(s,x,\dot{x})=l_x(s,x,\dot{x})$$

怎么解:

尽量只有 $\dot{x}$ $\ddot{x}$ x 的其中一种.

高次数相等可用"那个方法"

eg. $\dot{x}\ddot{x}^2+4\dot{x}^3+4\dot{x}\ddot{x}^2=0$

first order: $x^*\in C^1([s_1,s_2])$ is a weak local min. $\overset{\text{nec.}}{\Longrightarrow}$ EE satisfied.

- $p(s):=l_{\dot{x}}(s,x,\dot{x})$

$$H(s,x,\dot{x},p)=-l(s,x,\dot{x})+\dot{x}^Tp$$

$$\Longrightarrow \begin{cases}\dot{x}=H_p(s,x,\dot{x},p)\\ \dot{p}=-H_x(s,x,\dot{x},p)\end{cases}\quad(EE)$$

Lagrangian form 有两种常见特殊情况. (不太复杂时用, 太复杂时用反而不好解)

当有一种解不下去, 试下另一种.

1) $l=l(x,\dot{x})$

$$\Longrightarrow \frac{dH}{ds}=0\Longrightarrow H(s,x^*,\dot{x}^*,p^*)=\text{const}.$$

这样可以简化计算.

2) $l=l(s,\dot{x})$

$$\Longrightarrow \frac{dp}{ds}=0\Longrightarrow p(s)=\text{const}.$$

second order:

x^* weak local min. $\Longrightarrow$ EE , $+\ \nabla_{\dot{x}\dot{x}}l(s,x^*,\dot{x}^*)\ge 0$

$l(s,x,\dot{x})$ jointly convex in $x,\dot{x}$ (i.e. $z=\begin{bmatrix}x\\ \dot{x}\end{bmatrix}$ $\nabla_{zz}l\ge 0$) + EE $\overset{\text{suff.}}{\Longrightarrow}$ x^* global min.

有时我们会遇到 free end point 有 terminal cost free s_2

$$\min_{x(\cdot),\, s_2} J(x) = \min \int_{s_1}^{s_2} l(s,x,\dot{x})\,ds + \varphi(s_2, x(s_2))$$

$$x(s_1) = x_1 \quad x(s_2) \text{ free}, \quad s_2 \text{ free}.$$

$x^*(\cdot), s_2^*$ is a weak local min $\overset{\text{nec.}}{\Longrightarrow}$

① x^* solve EE on $[s_1, s_2^*]$

② transversal conditions.

A $\quad [\, l_{\dot{x}} + \varphi_x \,]\big|_{x=x^*,\, s=s_2^*} = 0 \quad \Longrightarrow x^*(s_2^*)$

B $\quad [\, l - \dot{x}^T l_{\dot{x}} + \varphi_s \,]\big|_{x=x^*,\, s=s_2^*} = 0 \quad \Longrightarrow s_2^*$

别忘了 $x(s_2) = x_2$ 这个条件

也就是说.

case 1: s_2 free $x(s_2)$ fixed. $\Longrightarrow$ EE + B

case 2: s_2 fixed $x(s_2)$ free $\Longrightarrow$ EE + A

case 3: s_2, $x(s_2)$ free. but $x(s_2) = \psi(s_2) \Longrightarrow$ EE +

$$[\, l + l_{\dot{x}}^T(\dot{\psi} - \dot{x}) + \varphi_s + \varphi_x^T \dot{\psi} \,]\big|_{x=x^*,\, s=s_2^*} = 0$$

when $\psi(\cdot) = \text{const}$. $\dot{\psi} = 0$, this is equal to B.

现在我们研究 $\hat{C}^1([s_1, s_2])$ with corner point $\{c_i\}_{i=1}^N$ fixed s_2

② Weierstrass - Erdmann (WE) conditions.

x^* is a strong min. $\xRightarrow{\text{nec.}}$

1) x^* solve EE in (c_i, c_{i+1}) for $i = 1, 2, \cdots$

2) for every $\{c_i\}_{i=1}^N$

2.1) $f_{\dot{x}}(c_i^-) = f_{\dot{x}}(c_i^+)$

2.2) $[-f(c_i^-) + \dot{x}^*(c_i^-)^T f_{\dot{x}}(c_i^-)] = [-f(c_i^+) + \dot{x}^*(c_i^+) f_{\dot{x}}(c_i^+)]$

weak min. $\Longrightarrow$ 2.1)

Strong min. $\Longrightarrow$ 2.1) + 2.2)

WE 可以把 strong 与 weak 分开. 且计算难度不高.

① 先用 EE 解出 x.

② 设计 $x = \begin{cases} \cdots & s_1 \sim c \\ \cdots & c \sim s_2 \end{cases}$

③ 用 2.1, 2.2 求解或验证.

一般 2.1 已经够解了.

2.2 只是进一步验证是否 strong.

- Weierstrass excess function.

$$E(s, x, \dot{x}, w) := f(s, x, w) - [f(s, x, \dot{x}) + (w - \dot{x})^T f_{\dot{x}}(s, x, \dot{x})]$$

x^* is strong min $\xRightarrow{\text{nec}}$

① x^* solve EE in (c_i, c_{i+1})

② $E(s, x^*, \dot{x}^*, w) \geq 0 \quad \forall w$ except corner point.

他可以在不知道 $\{c_i\}$ 的前提下验证一个解是否是可能的解.

↳ $E \geq 0$.

$$E(s, x^*, \dot{x}^*, w) = H(s, x^*, \dot{x}^*, p) - H(s, x^*, w, p)$$

that means. $H(s, x^*, \cdot, p)$ max. at $\dot{x}^*$.

这个在 strong min 时是 WE 的简化, 但有时计算很复杂.

③ Level-set constraints and isoperimetric constraints.

这个就有点抽象了. 像是 2.0 以上才能理解的.

fixed s_2

- Level-set constraints.

$$D = \bigcap_{i=1}^{n_g} \Lambda_i(k_i) \qquad \Lambda_i(k_i) := \{x \in V \mid G_i(x) \le k_i\} \quad i = 1, \cdots, n_g$$

Gateaux derivative

$$\delta J(x;\xi) := \lim_{\eta \to 0} \frac{J(x+\eta\xi) - J(x)}{\eta} = \frac{\partial}{\partial \eta} J(x+\eta\xi)\Big|_{\eta=0}.$$

相当于泛函的降落方向.

$$\delta^2 J(x;\xi) = \frac{\partial^2}{\partial \eta^2} J(x+\eta\xi)\Big|_{\eta=0}$$

这里 $J(x+\eta\xi)$ 是把所有拼成 $x+\eta\xi$ 包括 $\dot{x}$ 拼成 $(x+\eta\xi)^{\cdot}$

$\xi = \xi(s)$

- isoperimetric constraints. 一种特殊的 Level-set

$$\Lambda_i(k_i) := \{x \in V \mid G_i(x) = \int_{s_1}^{s_2} g_i(s, x(s), \dot{x}(s))\, ds = k_i\} \quad i = 1, \cdots, n_g$$

如果满足.

$$\mathrm{Det}(G(\{\zeta_i\}_{i=1}^{n_g})) \neq 0; \quad G(\{\zeta_i\}_{i=1}^{n_g}) := \begin{bmatrix} \delta G_1(x^*;\zeta_1) & \cdots & \delta G_1(x^*;\zeta_{n_g}) \\ \vdots & \ddots & \vdots \\ \delta G_{n_g}(x^*;\zeta_1) & \cdots & \delta G_{n_g}(x^*;\zeta_{n_g}) \end{bmatrix}$$

x^* is a weak local min. $\xrightarrow{\text{nec.}}$

$$\frac{d}{ds} L_{\dot{x}_i}(s, x^*(s), \dot{x}^*(s)) = L_{x_i}(s, x^*(s), \dot{x}^*(s))$$

$$L(s,x,\dot{x}) = \ell(s,x,\dot{x}) + \lambda^T g(s,x,\dot{x})$$

↓ Lagrange ↓ iso. constraints.

这个东西解起来是真复杂.

3. CV approach to Optimal Control (OC)

本章中，$V = \hat{C}([t_0, t_f])$ 间断点左右极限不一定相等。 之前是 C^1 现在是 C

$$\min_{u \in V} J(u)$$
$$\text{s.t. } \dot{x} = f(t, x, u),\ x(t_0) = x_0,\ t \in [t_0, t_f]$$
$$(t_f, x(t_f)) \in S \subseteq (t_0, \infty) \times \mathbb{R}^{n_x}$$

① $V = C([t_0, t_f], U)$ fixed t_f

Euler Lagrange equations (ELE)

u^* is a weak local min $\xrightarrow{\text{nec.}}$

$$\dot{x}^* = f(t, x^*, u^*),\quad x^*(t_0) = x_0$$

$x^*(t_f) = x_{t_f}$ 很少用 如果没给就换成 $\lambda^*(t_f) = 0$ ↳ 实际上是 $\lambda^*(t_f) = -\frac{\partial}{\partial x^*}$

给了也可以换 都能解出来。

$$\dot{\lambda}^* = l_x(t, x^*, u^*) - f_x(t, x^*, u^*)\lambda^*$$
$$0 = -l_u(t, x^*, u^*) + f_u(t, x^*, u^*)\lambda^*$$

$\forall t \in [t_0, t_f]$

$\Phi = \varphi + \nu\psi$

$-\nabla_{uu} l(t, x^*, u^*) + \nabla_{uu}(f(t, x^*, u^*)^T \lambda^*) \le 0$ 这个一般不用

我们规定：$H(t, x, u, \lambda) = -l(t, x, u) + f(t, x, u)^T \lambda(t)$

$\Longrightarrow$ ELE：

$$\dot{x}^* = H_\lambda(t, x^*, u^*, \lambda^*) \qquad x^*(t_0) = x_0$$
$$\dot{\lambda}^* = -H_x(t, x^*, u^*, \lambda^*) \qquad x^*(t_f) = x_{t_f} \ /\ \lambda^*(t_f) = 0.$$
$$0 = H_u(t, x^*, u^*, \lambda^*)$$

$\forall t \in [t_0, t_f]$

$H_{uu}(t, x^*, u^*, \lambda^*) \le 0$

Mangasarian conditions.

l and f jointly convex in x and u. ELE satisfied. $\lambda^*(t) \le 0 \quad \forall t \in [t_0, t_f]$

若 f 是相对 u, x 线性，则不需要这个条件。

$\xrightarrow{\text{suff.}}$ u^* global min.

② $C([t_0,t_1])$ with terminal cost. free t_f ✳ with constraints $x(t_f)=a$

$\psi(t,x)=x-a$

$$S=\{(t,x)\in[t_0,\infty)\times\mathbb{R}^{n_x}\mid \psi_k(t,x)=0,\ k=1,\cdots,n_\psi\}$$

$$\min_{u\in V,\ t_f}\int_{t_0}^{t_f} f(t,x,u)\,dt+\varphi(t_f,x(t_f))$$

$$\dot{x}=f(t,x,u),\quad x(t_0)=x_0$$

$$(t_f,x(t_f))\in S$$

$P_k(u,t_f):=\psi_k(t_f,x(t_f))$. 首先要满足 $\mathrm{Det}(P(\{\bar{\omega}_i,\bar{\tau}_i\}_{i=1}^{n_\psi}))\neq 0$; $P(\{\bar{\omega}_i,\bar{\tau}_i\}_{i=1}^{n_\psi}):=\begin{bmatrix}\delta P_1(u^*,t_f^*;\bar{\omega}_1,\bar{\tau}_1) & \cdots & \delta P_1(u^*,t_f^*;\bar{\omega}_{n_\psi},\bar{\tau}_{n_\psi})\\ \vdots & \ddots & \vdots\\ \delta P_{n_\psi}(u^*,t_f^*;\bar{\omega}_1,\bar{\tau}_1) & \cdots & \delta P_{n_\psi}(u^*,t_f^*;\bar{\omega}_{n_\psi},\bar{\tau}_{n_\psi})\end{bmatrix}$

u^* is a weak local min. $\xrightarrow{\text{nec.}}$ ELE.

$$\lambda^*(t_f^*)=-\mathcal{H}_x(t_f^*,x^*(t_f),\nu^*)$$

for $\mathcal{H}(t,x(t),\nu)=\varphi(t,x(t))+\nu^T\psi(t,x(t))$

$$0=\psi(t_f^*,x^*(t_f^*))\quad(\cdot)$$

$$0=\mathcal{H}_t(t_f^*,x^*(t_f),\nu^*)+H(t_f^*,x^*(t_f^*),u^*(t_f^*),\lambda^*(t_f^*))$$

是对 t 的偏导

如果 ψ 是 inequality constraints.

$(\cdot)$ 改成 $\psi(t_f^*,x^*(t_f^*))\le 0$

$$\nu^*\ge 0$$

$$\nu^{*T}\psi(t_f^*,x^*(t_f^*))=0$$

③ $V=\hat{C}([t_0,t_f])$ $\{c_i\}_{i=1}^N$ no terminal cost. fixed t_f

u^* is a weak local min. $\overset{\text{nec.}}{\Longrightarrow}$

$$x^*(c_i^-)=x^*(c_i^+)$$

$$\lambda^*(c_i^-)=\lambda^*(c_i^+)$$

$$H(c_i^-,x^*(c_i^-),u^*(c_i^-),\lambda^*(c_i^-))=H(c_i^+,x^*(c_i^+),u^*(c_i^+),\lambda^*(c_i^+))$$

但这并不常用.

- PMP. Pontryagin Maximum Principle. 这个常用

free t_f

$l=l(u,x)$ $f=f(u,x)$ time-invariant.

$\varphi=0$ no terminal cost.

通常 $u\in[-1,1]$.

① $\dot{x}^*=H_\lambda(x^*,u^*,\lambda^*,\lambda_0^*)$ $\lambda_0^*\le 0$ $(\lambda_0^*,\lambda_{(t)}^*)\neq(0,0)$

$\dot{\lambda}^*=-H_x(x^*,u^*,\lambda^*,\lambda_0^*)$

$$H(x,u,\lambda,\lambda_0)=\left\langle\begin{pmatrix}\lambda_0\\ \lambda\end{pmatrix},\begin{pmatrix}l(x,u)\\ f(x,u)\end{pmatrix}\right\rangle$$

② $H(x^*,u^*,\lambda^*,\lambda_0^*)\ge H(x^*,u,\lambda^*,\lambda_0^*)\Rightarrow u=\arg\max_u H(x^*,u,\lambda^*,\lambda_0^*)$

从这里入手

u^* 使 H 取最大值.

③ $H(x^*,u^*,\lambda^*,\lambda^*)=0$

④ 如果有 $S_f=\{x\mid h_i(x)=0,i=1,\dots n_h\}$

而不是 $x_f=k$ 这样的.

d 是的切

$\langle\lambda^*(t_f^*),d\rangle=0$ $\forall d\in T^{S_f}_{x^*(t_f^*)}$

等价于 $\lambda^*(t_f^*)=\nabla_x h(x)$

也就是 $\lambda^*(t_f^*)\perp d$.

4. Dynamic Programming and Optimal Control (动态规划)

本章是OC的恶魔之章，我至今不相信这题我考场上能写出来。

用来解多 stage 问题。 $u_1, u_2, u_3 \cdots$ 最优解。

①

$$\min_{\mu_k, \mu_{k+1} \cdots \mu_{T-1}} \quad g_T(x_T) + \sum_{k=i}^{T-1} g_k(x_k, \mu_k(x_k))$$

$$\text{s.t. } x_{k+1} = f_k(x_k, \mu_k(x_k)) \quad \cdot \ x_k \in X \quad \mu_k \in U$$

$$x_i \text{ given}, \ x_T \text{ free}.$$

μ_k 是对 u_k 的估计。

可从从任一k开始。

求得 $k \to T$ 这些步的最优解。

$f_k(x_k, \mu_k(x_k))$ 是 x_k 向 x_{k+1} 的变换关系。

要反向往前求。

$$V_T(x_T) = g_T(x_T)$$

$$V_k(x_k) = \min_{u_k} \left(g_k(x_k, u_k) + V_{k+1}(f_k(x_k, u_k)) \right) \quad k = 0, 1, \cdots T-1$$

$$\mu_k(x_k) := u_k^* \in \arg\min_{u_k \in U} \left(g_k(x_k, u_k) + V_{k+1}(f_k(x_k, u_k)) \right) \quad k = 0, 1, \cdots T-1$$

u_k 选取使 V_k 最小的 u_k。

问题在于 u 与 x 总是乱在一起，使 V_k 难以分布确认，有时只能从 T-0 把整个过程写出来。

② Hamilton - Jacobi - Bellman equation (HJB)

这个是 PMP 的变体。

$$\min_{u[t,t_f]} J(t,x,u) := \int_t^{t_f} l(s, x(s), u(x(s), s)\, ds + \varphi(x(t_f))$$

$$\text{s.t. } \dot{x} = f(t,x,u) \qquad x(t) = x$$

$$S = \{t_f\} \times \mathbb{R}^{n_x}, \ u \in U$$

让 $V(t,x) := \inf J(t,x,u)$

若满足 1) $-V_t(t,x) = \inf_{u \in U} \underbrace{l(t,x,u) + V_x(t,x) \cdot f(t,x,u)}_{\arg\min_u}$ 也就是 $V_t(t,x) = \sup_{u \in U} H(t,x,u,-V_x(t,x))$

V 连续，V_x 连续。

2) $V(t_f, x) = \varphi(x)$

那么 $u^*(x,t) \in \arg\max_{u \in U} H(t,x,u,-V_x(t,x))$

通常先用 解出 u 与 $V_x(t,x)$ 的关系。

再把 u 代回 H 中去尝试解 V

再得到 u。

$V(t,x)$ 非常难确定。

一般可以假设 $V(t,x) = a(t)x + b(t)$

or $a(t)x^2 + b(t)x + c(t)$

若 V 中无 t，那 $V_t(t,x) = 0$

限 ∞ 时使用

$+ \lim_{t \to \infty} V(t,x) = 0$

③ MDP.

这类问题在 x_k 向 x_{k+1} 转换时，有一个概率 $P(x_{k+1}|x_k,u_k)$

是①问题的复杂化。

$$J^*(x) = \min_{u\in U} g(x,u) + \alpha \sum_{x^+} P(x^+|x,u) J^*(x^+) = TJ^*(x)$$

$$\mu^*(x) = \arg\min_{u\in U} g(x,u) + \alpha \sum_{x^+} P(x^+|x,u) J^*(x^+)$$

$\alpha \in [0,1]$

解法：Bellman equations

① $J_{\mu_k}(x) = g(x,\mu_k(x)) + \alpha \sum_{x^+} p(x^+|x,\mu_k(x)) J_{\mu_k}(x^+)$

$$\boxed{J_{\mu_k} = (1-\alpha P_{\mu_k})^{-1} g_{\mu_k}}$$

② $\mu_{k+1} = \arg\min_{u\in U} g(x,u) + \alpha \sum_{x^+} p(x^+|x,u) J_{\mu_k}(x^+)$

这里有两种操作。

① PI (Policy iteration) for μ_k

已知 μ_k 求 J_{μ_k}　　知 J_{μ_k} 求 μ_{k+1} 与 $J_{\mu_{k+1}}$

已知 μ_k：① Policy evaluation and ② improvement. 来推断 μ_{k+1}

① $J_{\mu_k}(x) = g(x,\mu_k(x)) + \alpha \sum_{x^+} p(x^+|x,\mu_k(x)) J_{\mu_k}(x^+)$

$\boxed{J_{\mu_k} = (1-\alpha P_{\mu_k})^{-1} g_{\mu_k}}$ 用这个求出 J_{μ_k}，代入 ↓

② $\mu_{k+1} = \arg\min_{u\in U} g(x,u) + \alpha \sum_{x^+} p(x^+|x,u) J_{\mu_k}(x^+)$

用不同的 u 算一遍，min. 的是 μ_{k+1}

每次迭代都要经过 ① + ② 两个过程。

② 中得到的 J_{k+1} 不能直接用在下一次迭代

最终 μ_{k+N} 会稳定。

② Value iteration. (VI) for J_k

$$J_{k+1}(x) = \min_{u\in U} g(x,u) + \alpha \sum_{x^+\in X} P(x^+|x,\mu_k(x)) J_k(x^+)$$

注：

1) $P_u = \begin{bmatrix} P(1|1,u) & \cdots & P(n|1,u) \\ \vdots & \ddots & \\ \end{bmatrix}$ 是一个随 u 变化的矩阵

$g_u = \begin{bmatrix} g(1,u) \\ \vdots \\ g(n,u) \end{bmatrix}$

也就是说，决定了 μ 就决定了 P 与 g 再通过计算得到其它。

2) $u=\begin{bmatrix}1\\0\end{bmatrix}$ $u=\begin{bmatrix}0\\1\end{bmatrix}$ $u=\begin{bmatrix}0\\0\end{bmatrix}$ $u=\begin{bmatrix}1\\1\end{bmatrix}$

这四种情况，不需要我们算四次。

只算 $u=[0]$ 和 $u=[1]$ 即可。

这样我们就知道 $[\cdot]$ 是 $u=0$ 小还是 1 小，就可以直接知道 u 了

e.g. $u=\begin{bmatrix}0\\0\end{bmatrix} \Rightarrow \begin{bmatrix}-2\\1\end{bmatrix}$ $u=\begin{bmatrix}1\\1\end{bmatrix} \Rightarrow \begin{bmatrix}2\\0\end{bmatrix}$ $\Rightarrow \mu_{k+1}=\begin{bmatrix}0\\1\end{bmatrix}$

其实只要用这些就可以

BE $J^* = \min_{u\in U}(g_u + \alpha P_u J^*)$

opt u $\mu^* = \arg\min_{u\in U}(g_u + \alpha P_u J^*)$

VI $J_{k+1} = \min_{u\in U}(g_u + \alpha P_u J_k)$

PI $J_{\mu_k} = g_{\mu_k} + \alpha P_{\mu_k} J_{\mu_k} \Leftrightarrow J_{\mu_k} = (I - \alpha P_{\mu_k})^{-1} g_{\mu_k}$

PI $\mu_{k+1} = \arg\min_{u\in U}(g_u + \alpha P_u J_{\mu_k})$.

2025.3.16

教你解微分方程.

① $u=x^2$, $\dot{u}=2x\dot{x}$, $\ddot{u}=2(\dot{x}^2+x\ddot{x})$

这是一个经典代换.

② e.g. 像这样. $\ddot{x}+5tx=0$

可尝试 $x=c_1s+c_2e^{\lambda s}$ 来解.

③ $\dot{x}x+\ddot{x}x+\dot{x}^2=c$

一般可用 λ 方法解. 无解时尝试代换法.

$$J=\int_{s_1}^{s_2} l(s,x(s),\dot{x}(s))\,ds+\varphi(s_2,x(s_2))$$

$$=\int_{s_1}^{s_2} l(s,x(s),\dot{x}(s))+\dot{\varphi}(s,x(s))\,ds+\varphi(s_1,x(s_1))$$

DP 解 PDE 时 $V(t,x)$ 的选择. $V_t(t,x)$ 是对 t 的偏导.

① $t\to\infty$ 时. $V_t(t,x)=0$. 不需要选择 $V(t,x)$

② 非∞时. 是一个 $F(V_t(t,x))=G(V_x(t,x))$ 的PDE.

可假设 $V(t,x)=\alpha(t)+\beta(t)x$

这是个非常恶心的计算.

或 $V(t,x)=\alpha(t)+\beta(t)x+\gamma(t)x^2$

$$ay''+by'+cy=e^{rt}\cdot P_n(t)$$

齐次通解: $a\lambda^2+b\lambda+c=0$

① $\lambda_1\neq\lambda_2$ 实.

$y_h=c_1e^{\lambda_1 t}+c_2e^{\lambda_2 t}$

② $\lambda_1=\lambda_2$ 实

$y_h=c_1e^{\lambda_1 t}+c_2te^{\lambda_2 t}$

③ $\lambda_{1,2}=\alpha\pm i\beta$ 复.

$y_h=c_1e^{\alpha t}\cdot\sin(\beta t)+c_2e^{\alpha t}\cdot\cos(\beta t)$

r 与 λ 重复 a 次.

$y_p=t^a\cdot e^{rt}\cdot Q_n(t)$

$Q_n(t)$ 是与 $P_n(t)$ 同次的多项式.

(ax^2+bx+c)

解 y_p', y_p'' 代入除式得 $Q_n(t)$

通解.

$y=y_h+y_p$

— from OOD HM3学习会.